

我们对这个隐私替换 学到了什么。

两件事:它能不能保持数据可用,以及它藏得够不够。下面是对两点的诚实评估。

97 - 100%

只要它替换了某个信息,其他工具仍然能找到

替换让数据保持可用。

替换之后,其他工具几乎每次都还能认出敏感信息,而且格式(病历、表单、数据文件)完全不变,下游不会出错。

这是可以给客户看的亮点 —— 在全部 11 个工具、7 个数据集上都成立。

统计上:在被脱敏的 5.6 万个 span 上召回率 76.2% → 75.0%,等价检验证明变化在 ± 2 个百分点内可忽略($p \approx 1e-8$)。

在真实病历上,名字和日期藏得好,但漏掉了大约一半的 ID 号码和地址。

名字

约 4 个里藏 3 个

日期 / 年龄

约 4 个里藏 3 个

ID 号码(病人号、电话)

约 2 个里藏 1 个

地址 / 地点

约 2 个里藏 1 个

约 3/4

漏掉的里面,工具其实早就知道那是隐私

是“没替换”,不是“没找到”。

大部分漏掉的信息,工具已经标记成敏感了 —— 只是没去替换它。所以要修的是替换这一步,不是重新教它认隐私。

这是比较好解决的那类问题。



保持可用做得很好。下一步:藏得更全。

- 替换不会破坏任何东西 —— 这点可以直接给客户展示。
- 名字和日期藏得好,但漏掉约一半的 ID 号码和地址。
- 大部分漏掉的其实已经检测到 —— 修替换这一步就能补上。



→ custodianai.pages.dev